

Курсовая работа по классическому машинному обучению. Аналитический отчет.

Тема работы: Построение прогноза, позволяющего подобрать наиболее эффективное сочетание параметров для создания лекарственных препаратов.

Выполнил: Фролов И.В.

Оглавление

1. Постановка задачи

2. Анализ входных данных

3. Поиск информации в открытых источниках

3.1. Обзоры QSAR, дескрипторов и представлений

3.2. EDA: drug-likeness, ADMET, фильтрация

3.3. IC50, pIC50, противовирусная активность

3.4. CC50, цитотоксичность, селективность

3.5. Feature Engineering и отбор признаков

3.6. Валидация QSAR-моделей (методология EDA → ML)

4. Разработка структуры решения

5. Результаты

5.1 EDA

5.2 Feature engineering

5.3 Регрессия для pIC50

5.4 Регрессия для pCC50

5.5 Регрессия для log1p(SI)

5.6 Бинарный классификатор на целевой признак IC50 > median(IC50)

5.7 Бинарный классификатор на целевой признак CC50 > median(CC50)

5.8 Бинарный классификатор на целевой признак SI > median(SI)

5.9 Бинарный классификатор на целевой признак SI > 8

6. Выводы

1. Постановка задачи

Предоставлен датасет, содержащий 214 столбцов, из них:

- Unnamed: 0 - похож на id, не представляет информационной ценности
- "IC50, mM", "CC50, mM", "SI" - целевые параметры
- все остальные - молекулярные дескрипторы RDKit

Задачи:

- построить регрессию для IC50
- построить регрессию для CC50
- построить регрессию для SI
- построить бинарный классификатор на целевой признак IC50 > median(IC50)
- построить бинарный классификатор на целевой признак CC50 > median(CC50)
- построить бинарный классификатор на целевой признак SI > median(SI)
- построить бинарный классификатор на целевой признак SI > 8

2. Анализ входных данных

У меня нет (кроме школьных) знаний в области химии и фармакологии, поэтому при первом подходе было мнение, что если разобраться во входных данных, это поможет в дальнейшем выбрать правильные признаки и их комбинации. В результате анализа открытых источников по заданной тематике удалось восстановить функциональное описание дескрипторов RDKit и сгруппировать их следующим образом (можно пропустить и перейти к следующему разделу).

Электротопологическое состояние (E-State)

Столбец	Полное название	Описание
MaxAbsEStateIndex	Maximum absolute E-State index	Максимальное по модулю значение индекса электротопологического состояния (E-State) среди атомов молекулы. Характеризует наиболее "экстремальный" электронный вклад на поверхности.

Столбец	Полное название	Описание
MaxEStateIndex	Maximum E-State index	Максимальное (алгебраическое) значение E-State по атомам.
MinAbsEStateIndex	Minimum absolute E-State index	Минимальное по модулю значение E-State (наименее выраженное электротопологическое состояние).
MinEStateIndex	Minimum E-State index	Минимальное (алгебраическое) значение E-State по атомам.

Скрининговые и обобщённые показатели "лекарственности"

Столбец	Полное название	Описание
qed	Quantitative Estimate of Drug-likeness	Количественная оценка "лекарственности" (0–1): насколько структура похожа на типичные пероральные лекарства (масса, LogP, доноры/акцепторы Н-связи, ароматичность, ротационные связи). Ближе к 1 - более "drug-like" профиль.
SPS	Synthetic Accessibility Score	Оценка синтетической доступности (шкала RDKit, обычно 1–10): насколько сложно синтезировать соединение. Высокие значения - проще для химического синтеза.

Масса, состав и электронная структура

Столбец	Полное название	Описание
MolWt	Molecular Weight	Молекулярная масса (г/моль): сумма атомных масс всех атомов в формуле.
HeavyAtomMolWt	Heavy Atom Molecular Weight	Молекулярная масса без учёта водорода (только "тяжёлые" атомы: C, N, O, S, галогены и т.д.).
ExactMolWt	Exact Molecular Weight	Точная молекулярная масса с учётом наиболее распространённых изотопов (не усреднённая табличная).
NumValenceElectrons	Number of Valence Electrons	Общее число валентных электронов в молекуле.
NumRadicalElectrons	Number of Radical	Число неспаренных (радикальных) электронов. Ненулевое значение указывает

Столбец	Полное название	Описание
	Electrons	на реакционноспособные/нестабильные формы.

Частичные заряды (Gasteiger)

Столбец	Полное название	Описание
MaxPartialCharge	Maximum Partial Charge	Максимальный частичный атомный заряд (модель Gasteiger–Marsili).
MinPartialCharge	Minimum Partial Charge	Минимальный частичный заряд (наиболее отрицательный атом).
MaxAbsPartialCharge	Maximum Absolute Partial Charge	Максимальный модуль частичного заряда - мера полярности/локальной электрофильности.
MinAbsPartialCharge	Minimum Absolute Partial Charge	Минимальный модуль частичного заряда среди атомов.

Отпечатки Morgan (плотность битов)

Столбец	Полное название	Описание
FpDensityMorgan1	Morgan Fingerprint Density, radius 1	Доля установленных битов в отпечатке Morgan (радиус 1): "плотность" структурной информации на коротких радиусах.
FpDensityMorgan2	Morgan Fingerprint Density, radius 2	То же для радиуса 2 (более крупные окружения атомов).
FpDensityMorgan3	Morgan Fingerprint Density, radius 3	То же для радиуса 3 (максимальный охват локальной структуры в этой тройке).

BCUT2D (собственные значения матрицы Бурдена, 2D)

Дескрипторы BCUT строятся из собственных значений матрицы связей, взвешенной атомными свойствами. Пары *HI / *LOW - верхний и нижний пределы распределения по молекуле.

Столбец	Полное название	Описание
BCUT2D_MWHI	BCUT2D - molecular weight, high	Верхняя граница вклада молекулярной массы в BCUT-пространстве.
BCUT2D_MWLOW	BCUT2D - molecular weight, low	Нижняя граница вклада молекулярной массы.
BCUT2D_CHGHI	BCUT2D - Gasteiger charge, high	Верхняя граница по частичным зарядам.
BCUT2D_CHGLO	BCUT2D - Gasteiger charge, low	Нижняя граница по зарядам.
BCUT2D_LOGPHI	BCUT2D - Crippen LogP, high	Верхняя граница по липофильности (LogP).
BCUT2D_LOGPLOW	BCUT2D - Crippen LogP, low	Нижняя граница по LogP.
BCUT2D_MRHI	BCUT2D - molar refractivity, high	Верхняя граница по молярной рефракции.
BCUT2D_MRLOW	BCUT2D - molar refractivity, low	Нижняя граница по молярной рефракции.

Топологические индексы связности и формы

Столбец	Полное название	Описание
AvgIpc	Average Information Content	Средняя информационная насыщенность графа молекулы (разнообразие окружений атомов).
BalabanJ	Balaban J Index	Топологический индекс Балабана J: чувствителен к разветвлению и "длине" молекулы.
BertzCT	Bertz Complexity Index	Индекс сложности Берца (СТ): комбинаторная мера структурной сложности.
Chi0	Chi0 connectivity index	Индекс связности χ^0 (нулевого порядка): учитывает число атомов и связей.
Chi0n	Chi0n (normalized)	Нормированный χ^0 .
Chi0v	Chi0v (valence)	χ^0 с валентными весами атомов.
Chi1	Chi1 connectivity index	Индекс связности χ^1 (первого порядка): пути из двух связей.
Chi1n	Chi1n (normalized)	Нормированный χ^1 .
Chi1v	Chi1v (valence)	χ^1 с валентными весами.
Chi2n	Chi2n	Нормированный индекс связности χ^2 .
Chi2v	Chi2v	χ^2 с валентными весами.

Столбец	Полное название	Описание
Chi3n	Chi3n	Нормированный χ^3 .
Chi3v	Chi3v	χ^3 с валентными весами.
Chi4n	Chi4n	Нормированный χ^4 .
Chi4v	Chi4v	χ^4 с валентными весами.
HallKierAlpha	Hall–Kier Alpha	Параметр α Холла–Киера: коррелирует с числом колец и молекулярной "плотностью".
Ipc	Information Content	Информационное содержание молекулярного графа (энтропия распределения атомных типов).
Kappa1	Kappa1 shape index	Индекс формы κ_1 : отношение числа атомов к порядку связности (размер/ветвление).
Kappa2	Kappa2 shape index	κ_2 : учитывает число путей длины 2 (разветвление).
Kappa3	Kappa3 shape index	κ_3 : пути длины 3 (удлинённость/гибкость каркаса).
LabuteASA	Labute Approximate Surface Area	Приближённая доступная поверхность по методу Labute ($\text{\AA}^2$): оценка контакта с растворителем/мишенью.

VSA-дескрипторы (Van der Waals Surface Area по бинам свойств)

Молекула разбивается на атомы и каждому атому присваивается свойство и площадь поверхности, затем площади суммируются по диапазонам (бинам) свойства.

PEOE_VSA - по частичному заряду (PEOE)

Столбец	Описание
PEOE_VSA1 ... PEOE_VSA14	Суммарная VSA атомов с частичным зарядом в соответствующем диапазоне PEOE (Partial Equalization of Orbital Electronegativities). Разные номера - разные интервалы заряда: от слабо полярных до сильно заряженных областей. Высокие значения в "крайних" бинах указывают на выраженные полярные/заряженные участки молекулы.

SMR_VSA - по молярной рефракции

Столбец	Описание
SMR_VSA1 ... SMR_VSA10	Распределение площади поверхности по бинам молярной рефракции (поляризуемость/объём атомных фрагментов). Отражает, где на молекуле сосредоточены поляризуемые фрагменты.

SlogP_VSA - по липофильности (LogP)

Столбец	Описание
SlogP_VSA1 ... SlogP_VSA12	Распределение поверхности по бинам рассчитанного LogP атомных вкладов (Crippen/Wildman–Crippen). Показывает, какая доля поверхности гидрофобна или гидрофильна.

EState_VSA и VSA_EState - по E-State

Столбец	Описание
EState_VSA1 ... EState_VSA11	Сумма площадей атомов, сгруппированных по бинам индекса E-State.
VSA_EState1 ... VSA_EState10	Сумма E-State × площадь по бинам VSA (взвешенное электротопологическое состояние на поверхности).

Липофильность, полярность и рефракция (скалярные)

Столбец	Полное название	Описание
TPSA	Topological Polar Surface Area	Топологическая полярная площадь поверхности ($\text{\AA}^2$): сумма вкладов полярных атомов (N, O и др.). Высокая TPSA - лучшая растворимость, хуже проникновение через ГЭБ, низкая - наоборот.
MolLogP	Wildman–Crippen LogP	Коэффициент распределения октанол/вода (log P): мера липофильности. Критичен для мембранного транспорта и токсичности.
MolMR	Molar Refractivity	Молярная рефракция ($\text{м}^3 \cdot 10^{-2}/\text{моль}$): связана с объёмом и поляризуемостью молекулы.

Структурные счётчики (кольца, гетероатомы, водородные связи)

Столбец	Полное название	Описание
FractionCSP3	Fraction of sp^3 Carbons	Доля атомов углерода в sp^3 -гибридизации (0–1). Выше - более "насыщенная", менее плоская 3D-структура.
HeavyAtomCount	Heavy Atom Count	Число атомов тяжелее водорода.
NHONCount	NH and OH Count	Число атомов N и O в группах NH/OH (доноры H-связи).
NOCOUNT	Nitrogen and Oxygen Count	Общее число атомов N и O.
NumAliphaticCarbocycles	Number of Aliphatic Carbocycles	Число алифатических карбоциклов (циклы только из C).
NumAliphaticHeterocycles	Number of Aliphatic Heterocycles	Число алифатических гетероциклов.
NumAliphaticRings	Number of Aliphatic Rings	Суммарно алифатических колец (карбо- + гетеро-).
NumAromaticCarbocycles	Number of Aromatic Carbocycles	Число ароматических карбоциклов (например, бензольных колец).
NumAromaticHeterocycles	Number of Aromatic Heterocycles	Число ароматических гетероциклов (пиридин, имидазол и т.п.).
NumAromaticRings	Number of Aromatic Rings	Всего ароматических колец.
NumHAcceptors	Number of H-Bond Acceptors	Число акцепторов водородной связи (по Lipinski).
NumHDonors	Number of H-Bond Donors	Число доноров водородной связи.
NumHeteroatoms	Number of Heteroatoms	Число гетероатомов (не C и не H).
NumRotatableBonds	Number of Rotatable Bonds	Число вращаемых одинарных связей (гибкость, влияет на энтропию связывания).
NumSaturatedCarbocycles	Number of Saturated Carbocycles	Число насыщенных карбоциклов.
NumSaturatedHeterocycles	Number of Saturated	Число насыщенных гетероциклов.

Столбец	Полное название	Описание
	Heterocycles	
NumSaturatedRings	Number of Saturated Rings	Всего насыщенных колец.
RingCount	Ring Count	Общее число колец любого типа.

Фрагментные дескрипторы (fr_*)

Счётчики вхождений функциональных групп и подструктур (SMARTS-паттерны RDKit Fragments). Значение - число совпадений в молекуле (0, если группы нет).

Столбец	Полное название / фрагмент	Описание
fr_Al_COO	Aliphatic carboxylic acid	Алифатическая карбоксильная кислота (–COOH на алкильном углероде).
fr_Al_OH	Aliphatic hydroxyl	Алифатический спирт (–OH на sp^3 -углероде).
fr_Al_OH_noTert	Aliphatic hydroxyl (non-tertiary)	Алифатический –OH не третичный.
fr_ArN	Aromatic nitrogen	Азот в ароматическом кольце (например, в пиридине).
fr_Ar_COO	Aromatic carboxylic acid	Карбоксильная группа, связанная с ароматическим углеродом.
fr_Ar_N	Aromatic N (general)	Ароматический атом азота (широкий паттерн).
fr_Ar_NH	Aromatic NH	Ароматический NH (например, индольный NH).
fr_Ar_OH	Aromatic hydroxyl	Фенольный OH (ароматический спирт).
fr_COO	Carboxylic acid / ester carbonyl context	Карбоксильная/карбонильная подструктура (COO).
fr_COO2	Carboxylate / di-oxygen carbonyl	Расширенный паттерн двухкислородного карбонила (карбоксилаты, эфиры карб. к-ты).
fr_C_O	Carbonyl	Карбонильная группа C=O (общий).
fr_C_O_noCOO	Carbonyl (not carboxyl/ester)	C=O вне карбоксилата/эфира карб. к-ты (кетоны, альдегиды, амиды).
fr_C_S	Carbon–sulfur	Связь C–S.

Столбец	Полное название / фрагмент	Описание
fr_HOCCN	HO–C–C–N motif	Фрагмент HO–CH–CH–N (типичен для аминокислот).
fr_Imine	Imine	Иминовая группа C=N.
fr_NH0	Tertiary amine nitrogen	Третичный амин (N без H).
fr_NH1	Secondary amine	Вторичный амин (NH).
fr_NH2	Primary amine	Первичный амин (NH_2).
fr_N_O	N–O bond	Связь азот–кислород (N-оксиды, нитрозо и др.).
fr_Ndealkylation1	N-dealkylation site (type 1)	Мотив, подверженный N-деалкилированию (метаболизм, тип 1).
fr_Ndealkylation2	N-dealkylation site (type 2)	Мотив N-деалкилирования тип 2.
fr_Nhpyrrole	N-H pyrrole	Пиррольный NH (донор H-связи в пятичленном кольце).
fr_SH	Thiol	Тиол –SH.
fr_aldehyde	Aldehyde	Альдегид –CHO.
fr_alkyl_carbamate	Alkyl carbamate	Карбамат (алкиловый эфир карбаминовой кислоты).
fr_alkyl_halide	Alkyl halide	Алкилгалогенид (F, Cl, Br, I на алкиле).
fr_allylic_oxid	Allylic oxidation site	Союзно-аллильный углерод (сайт окисления).
fr_amide	Amide	Амидная связь –CONH–.
fr_amidine	Amidine	Амидин (протонированные имины, часто сильные основания).
fr_aniline	Aniline	Анилин (ароматический NH_2).
fr_aryl_methyl	Aryl methyl	Метильная группа у ароматического кольца (бензиловый CH_3).
fr_azide	Azide	Азид – N_3 .
fr_azo	Azo	Азо-группа –N=N–.
fr_barbitur	Barbiturate	Ядро барбитурата (седативные/противоэпилептические скелеты).
fr_benzene	Benzene ring	Бензольное кольцо (моноклическое ароматическое C_6).

Столбец	Полное название / фрагмент	Описание
fr_benzodiazepine	Benzodiazepine	Скелет бензодиазепина (анксиолитики).
fr_bicyclic	Bicyclic system	Бициклическая система (два сопряжённых кольца).
fr_diazo	Diazo	Диазо-группа $-N_2$.
fr_dihydropyridine	Dihydropyridine	Дигидропиридиновое кольцо (блокаторы кальциевых каналов).
fr_epoxide	Epoxide	Эпоксидное трёхчленное кольцо C–O–C.
fr_ester	Ester	Сложный эфир $-COO-$ (не карб. к-та).
fr_ether	Ether	Простой эфир C–O–C.
fr_furan	Furan	Кольцо фурана.
fr_guanido	Guanidine	Гуанидиновая группа (аргининоподобные, сильные основания).
fr_halogen	Halogen (any)	Наличие галогена на молекуле.
fr_hdrzine	Hydrazine	Гидразин $-NHNH-$.
fr_hdrzone	Hydrazone	Гидразон $C = N - NH_2$.
fr_imidazole	Imidazole	Кольцо имидазола.
fr_imide	Imide	Имид (два C=O у N).
fr_isocyan	Isocyanide	Изонитрил $-NC$.
fr_isothiocyan	Isothiocyanate	Изотиоцианат $-N=C=S$.
fr_ketone	Ketone	Кетон $R-CO-R'$.
fr_ketone_Topliss	Topliss ketone	Кетон в контексте Topliss-аналогов (QSAR-оптимизация).
fr_lactam	Lactam	Лактам (циклический амид, β -лактамы - антибиотики).
fr_lactone	Lactone	Лактон (циклический эфир).
fr_methoxy	Methoxy	Метоксигруппа $-OCH_3$.
fr_morpholine	Morpholine	Кольцо морфолина.
fr_nitrile	Nitrile	Нитрил $-C \equiv N$.
fr_nitro	Nitro	Нитро-группа $-NO_2$.
fr_nitro_ arom	Aromatic nitro	Нитро на ароматическом кольце.
fr_nitro_ arom_nonortho	Aromatic nitro (non-ortho)	Ароматический NO_2 не в орто-положении к другому заместителю.

Столбец	Полное название / фрагмент	Описание
fr_nitroso	Nitroso	Нитрозо –NO.
fr_oxazole	Oxazole	Кольцо оксазола.
fr_oxime	Oxime	Оксим C=N–OH.
fr_para_hydroxylation	Para-hydroxylation site	Сайт пара-гидроксилирования (метаболизм фенолов).
fr_phenol	Phenol	Фенол (ароматический OH).
fr_phenol_noOrthoHbond	Phenol without ortho H-bond	Фенол без орто-группы для внутримолекулярной H-связи.
fr_phos_acid	Phosphoric acid	Фосфорная кислота / фосфат.
fr_phos_ester	Phosphate ester	Фосфатный эфир.
fr_piperdine	Piperidine	Кольцо пиперидина (насыщенное 6-членное с N).
fr_piperzine	Piperazine	Кольцо пиперазина (два N в 6-членном кольце).
fr_priamide	Primary amide	Первичный амид –CONH ₂ .
fr_prisulfonamd	Primary sulfonamide	Первичный сульфонамид –SO ₂ NH ₂ .
fr_pyridine	Pyridine	Кольцо пиридина.
fr_quatN	Quaternary nitrogen	Четвертичный азот (N ⁺ , постоянный заряд).
fr_sulfide	Sulfide	Сульфид R–S–R'.
fr_sulfonamd	Sulfonamide	Сульфонамид –SO ₂ NH–.
fr_sulfone	Sulfone	Сульфон –SO ₂ (два кислорода на S).
fr_term_acetylene	Terminal acetylene	Терминальный ацетилен –C ≡ CH.
fr_tetrazole	Tetrazole	Кольцо тетразола (биоизостер карбоксилата).
fr_thiazole	Thiazole	Кольцо тиазола (S и N в 5-членном кольце).
fr_thiocyan	Thiocyanate	Роданид –SCN.
fr_thiophene	Thiophene	Кольцо тиофена.
fr_unbrch_alkane	Unbranched alkane	Неразветвлённый алкан (линейная алкильная цепь).
fr_urea	Urea	Мочевина –NH–CO–NH–.

3. Поиск информации в открытых источниках

После того, как сформировано какое-то представление о входных данных перехожу к анализу открытых источников и поиску информации по заданной тематике (регрессия на IC50 / CC50 / SI)

Результаты поиска:

3.1. Обзоры QSAR, дескрипторов и представлений молекул

3.1.1 Molecular representations in AI-driven drug discovery: a review and practical guide

Авторы	Wu Z. et al.
Журнал	<i>Journal of Cheminformatics</i> (2020)
Ссылка	https://jcheminf.biomedcentral.com/articles/10.1186/s13321-020-00460-5
DOI	10.1186/s13321-020-00460-5

Практическое руководство по представлениям молекул для ML: 1D-дескрипторы, отпечатки, графы. Подчёркивается, что выбор кодирования структуры сильно влияет на качество модели, "универсального" представления нет - нужно сопоставлять задачу и объём данных.

Сильные решения для проекта

- Использовать комбинацию RDKit 2D (MolWt, TPSA, LogP, Chi, VSA) и, при необходимости, Morgan/ECFP для дополнительного эксперимента
- В EDA явно описать тип признаков (конституциональные, топологические, фрагментные)
- Не полагаться только на сотни коррелированных VSA: агрегировать (sum/max/entropy)

3.1.2 Integrating QSAR modelling and deep learning in drug discovery: the emergence of deep QSAR

Авторы	Wieder O. et al.
Журнал	<i>Nature Reviews Drug Discovery</i> (2024)
Ссылка	https://www.nature.com/articles/s41573-023-00832-0
DOI	10.1038/s41573-023-00832-0

Обзор эволюции QSAR → deep learning. Главный вывод для малых табличных датасетов (~10³ соединений): качество и курация данных важнее архитектуры, классические дескрипторы + RF/XGB часто конкурентоспособны с GNN.

Сильные решения для проекта

- На текущем объёме (~1000 строк) приоритет - чистый EDA, pIC50, отбор признаков, а не усложнение модели
- Документировать протокол (трансформация y, split, метрики)

3.1.3 A review of quantitative structure-activity relationship (datasets, descriptors, models)

Авторы	(обзор 2024, <i>Chemometrics and Intelligent Laboratory Systems</i>)
Ссылка	https://www.sciencedirect.com/science/article/abs/pii/S0169743924002181
DOI	10.1016/j.chemolab.2024.104955

Систематизация этапов QSAR: курация структур, дескрипторы, модели, валидация. Акцент на избыточности дескрипторов и риске переобучения при $p \gg n$.

Сильные решения для проекта

- После FE (~80+ признаков при ~1000 объектов) обязателен жёсткий отбор (корреляции, RFE, LASSO).
- Вести журнал удалённых признаков и причин (константа, низкая дисперсия, corr > 0.9).

3.2. EDA: drug-likeness, ADMET, фильтрация

3.2.1 TeachOpenCADD T002 - Molecular filtering: ADME and lead-likeness criteria

Источник	Volkamer lab (открытый курс CADD)
Ссылка	https://projects.volkamerlab.org/teachopencadd/talktorials/T002_compound_ad
Код	https://github.com/volkamerlab/teachopencadd/blob/master/teachopencadd/tall

Пошаговый EDA: расчёт MW, LogP, HBD, HBA, TPSA, проверка правила Липинского, визуализация (radar plots), фильтрация библиотеки.

Сильные решения для проекта

- Добавить radar chart для топ-10 соединений с лучшим SI и худшим SI.
- Считать число нарушений Ro5 и связь с CC50 (токсичность).
- Расширить FE: не только Lipinski, но Veber (rotatable bonds ≤ 10 , TPSA $\leq 140 \text{ \AA}^2$).

3.2.2 Benchmarking ML in ADMET predictions: practical impact of feature representations

Журнал	<i>Journal of Cheminformatics</i> (2025), open access
Ссылка	https://link.springer.com/article/10.1186/s13321-025-01041-0
DOI	10.1186/s13321-025-01041-0

Сравнение представлений для ADMET: итеративное объединение фич с проверкой значимости (CV + статистические тесты), очистка SMILES, scaffold split, оценка переноса между датасетами. Random Forest часто силён на табличных ADMET-задачах.

Сильные решения для проекта

- Очистка данных: канонические SMILES, дедупликация (аналог REDIAL).
- Scaffold split при обучении (химическая новизна в тесте).
- Отбор признаков: добавлять блоки дескрипторов (VSA, fr, BCUT) по одному и сравнивать CV-RMSE для pIC50 / pCC50.
- CC50 ближе к ADMET "toxicity" - ориентир на протоколы из этой статьи.

3.2.3 DBPP-Predictor: drug-likeness based on property profiles

Журнал	<i>Journal of Cheminformatics</i> (2024)
Ссылка	https://link.springer.com/article/10.1186/s13321-024-00800-9
DOI	10.1186/s13321-024-00800-9

Drug-likeness через профили свойств (не один qed, а вектор физхим + ADMET-подобных признаков).

Сильные решения для проекта

- Объединить qed, LipinskiScore, TPSA/MolWt в единый Property Profile Vector для кластеризации соединений в EDA.
 - Сравнить кластеры с медианным SI (есть ли "зона" drug-like с высокой селективностью).
-

3.3. IC50, pIC50, противовирусная активность

3.3.1 A machine learning platform to estimate anti-SARS-CoV-2 activities (REDIAL-2020)

Авторы	Ton A.-M. et al.
Журнал	<i>Nature Machine Intelligence</i> (2021)
Ссылка	https://www.nature.com/articles/s42256-021-00335-w
DOI	10.1038/s42256-021-00335-w
Веб-сервис	http://drugcentral.org/Redial

Платформа из 11 моделей: вирусная активность (CPE) и цитотоксичность (cytotox) параллельно. EDA: PCA на VolSurf+ → фильтры logP/logS, дескрипторы - RDKit + отпечатки + фармакофоры, консенсус моделей, балансировка классов при HTS.

Сильные решения для проекта (максимально близко к IC50/CC50/SI)

- Раздельное моделирование potency (IC50) и toxicity (CC50), при этом SI = отношение - проверять согласованность предсказаний.
- PCA до ML: визуализация активных vs неактивных в пространстве дескрипторов
- Фильтрация по MolLogP / растворимости только если не отсекает >15% "хороших"
- Консенсус: RF на RDKit + важные fr/VSA, для классификации SI > 8 - voting.
- Стандартизация структур (соли, таутомеры) - если появятся SMILES.

3.3.2 QSAR Modeling for Predicting IC50 and GI50 Values for Human Cell Lines

Авторы	Lagunin A. A. et al.
Журнал	<i>International Journal of Molecular Sciences</i> (2025)
Ссылка	https://www.mdpi.com/1422-0067/26/24/12063
PMC	https://pmc.ncbi.nlm.nih.gov/articles/PMC12733303/
DOI	10.3390/ijms262412063

QSAR для IC50 и GI50 (ростовые ингибирующие концентрации) на 20 линиях клеток, дескрипторы QNA/MNA, 5-fold CV, $R^2 \approx 0.69$, $RMSE \approx 0.58$ в log-шкале. Связано с веб-сервером CLC-Pred 2.0.

Сильные решения для проекта

- Предсказывать логарифм концентрации (аналог pIC50), не сырые mM.
- Метрики: RMSE в log-шкале.

- Общие дескрипторы (LogP, TPSA, aromatic rings).

3.3.3 Comparison of QSAR models for Ki and IC50 (antitarget inhibitors)

Журнал	<i>Frontiers in Pharmacology</i> (2018)
Ссылка	https://www.frontiersin.org/journals/pharmacology/articles/10.3389/fphar.2018.011136
DOI	10.3389/fphar.2018.011136

Сравнение количественных и качественных QSAR для IC50: бинаризация vs регрессия в log-шкале. Для широкого диапазона IC50 регрессия на преобразованной шкале стабильнее.

Сильные решения для проекта

- Регрессия: pIC50 / pCC50 - отдельные пороги с проверкой баланса классов.
- Не смешивать трансформации: SI не через $-\log_{10}(\text{mM})$.

3.4. CC50, цитотоксичность, селективность

3.4.1 Predictive Models For Estimating Cytotoxicity On The Basis Of Chemical Structures

Авторы	Sun H. et al. (NCATS)
Журнал	<i>Bioorganic & Medicinal Chemistry</i> (2020)
Ссылка	https://doi.org/10.1016/j.bmc.2020.115422
PMC	https://pmc.ncbi.nlm.nih.gov/articles/PMC7881917/

~10 000 соединений, 4 линии клеток, модели SVM по структуре, AUC $\approx$ 0.88–0.90, undersampling для дисбаланса (11.8% цитотоксичных). Анализ общих субструктур у токсичных соединений.

Сильные решения для проекта

- Модель CC50: ожидать дисбаланс "высокая токсичность" vs "низкая" при бинаризации по медиане.
- Undersampling / class_weight в классификаторе CC50.
- EDA: какие fr_nitro, fr_aldehyde, aromatic rings связаны с низким CC50 (высокая токсичность).

3.4.2 CLC-Pred 2.0 - in silico cell line cytotoxicity

Авторы	Lagunin A. A. et al.
Журнал	<i>International Journal of Molecular Sciences</i> (2023)
Ссылка	https://www.mdpi.com/1422-0067/24/2/1689
DOI	10.3390/ijms24021689

Веб-сервер прогноза цитотоксичности и MOA для drug-like соединений, развитие CLC-Pred, связка с QSAR по линиям клеток.

Сильные решения для проекта

- Трактовать CC50 как cytotoxicity endpoint - отдельная модель и отдельный EDA (не только как "второй IC50").
- При интерпретации: therapeutic window $\approx$ SI

3.4.3 Leveraging viral genome sequences and ML for selective antiviral agents

Журнал	<i>Communications Chemistry</i> (2025)
Ссылка	https://www.nature.com/articles/s42004-025-01583-2
DOI	10.1038/s42004-025-01583-2

Виртуальный скрининг: модели virus-selective vs pan-antiviral, отдельные QSAR на цитотоксичность (Tox21), отбор кандидатов: активность + non-cytotoxic, ECFP4, feature selection (Fisher, XGB), max Tanimoto для applicability domain.

Сильные решения для проекта

- Двухконтурная логика: "сильный IC50" и "слабый CC50" $\rightarrow$ высокий SI.
- Applicability domain: для экстремальных SI проверять Tanimoto к ближайшим соседям в train.
- Отбор признаков: union top features + cap (как в их FS pipeline).

3.5. Feature Engineering и отбор признаков

3.5.1 Representative Feature Selection (RFS) of molecular descriptors in QSAR

Авторы	Li J. et al.
Журнал	<i>Journal of Molecular Structure</i> (2021)
Ссылка	https://www.sciencedirect.com/science/article/pii/S0022286021013788
DOI	10.1016/j.molstruc.2021.131249

Метод RFS: кластеризация дескрипторов, удаление избыточности по Pearson ($|r| > 0.8$), выбор представителей в кластере. На ~1850 MD снижение redundancy улучшает QSAR vs "слепое" PCA.

Сильные решения для проекта

- Заменить или дополнить `remove_highly_correlated(threshold=0.9)` методом "один представитель из кластера высокой корреляции" - сохраняется разнообразие химической информации.
- Перед отбором: кластерная карта корреляций (как clustermap, но с аннотацией групп VSA/Chi/fr).

3.5.2 A comprehensive comparison of molecular feature representations for predictive modeling

Журнал	<i>Computers in Biology and Medicine</i> (2020)
Ссылка	https://www.sciencedirect.com/science/article/abs/pii/S001048252030528X
DOI	10.1016/j.combiomed.2020.104076

Сравнение MACCS, ECFP, RDKit 2D, PaDEL на разных endpoint'ax. PaDEL силён для физических свойств, MACCS - простой сильный baseline, комбинации часто лучше одного типа.

Сильные решения для проекта

- Baseline-модель только на {MolWt, MolLogP, TPSA, NumHDonors, NumHAcceptors, RingCount} vs полный набор - оценить прирост от FE.
- Опционально: добавить MACCS keys (167 бит) как отдельный эксперимент.

3.6. Валидация QSAR-моделей (методология EDA → ML)

3.6.1 Best Practices for QSAR Model Development, Validation, and Exploitation

Авторы	Tropsha A., Gramatica P., Gombar V. K.
Журнал	<i>Molecular Informatics</i> (2010), обзор на PubMed
Ссылка	https://doi.org/10.1002/minf.201000061
PubMed	https://pubmed.ncbi.nlm.nih.gov/27463326/

Классический чеклист QSAR: курация структур, outliers, разделение train/test, applicability domain, внешняя валидация, Y-scrambling.

Сильные решения для проекта

- После EDA: список химических выбросов (не только IQR по признакам, но и по остаткам будущей модели).
- Y-scrambling: перетасовать SI/IC50, убедиться что R^2 падает (контроль переобучения).
- Не использовать все 200+ признаков без отбора при $n \approx 1000$.

3.6.2 Reliable estimation of prediction errors using double cross-validation

Журнал	<i>Journal of Cheminformatics</i> (2014)
Ссылка	https://jcheminf.biomedcentral.com/articles/10.1186/s13321-014-0047-1
DOI	10.1186/s13321-014-0047-1

Nested CV даёт несмещённую оценку ошибки при одновременном подборе гиперпараметров и отборе признаков.

Сильные решения для проекта

- Внутренний цикл: отбор признаков + RF, внешний: RMSE pIC50 / pCC50.
- Не сообщать метрику только на одном hold-out после "подглядывания" в те же данные при FE.

3.6.3 Beware of R^2 : assessment of prediction accuracy of QSAR models

Журнал	<i>Journal of Chemical Information and Modeling</i> (2015)
PMC	https://www.ncbi.nlm.nih.gov/pmc/articles/PMC4530125/
DOI	10.1021/acs.jcim.5b00206

R^2 на обучении завышает качество, рекомендуются Q^2 , RMSE, MAE на CV и внешнем тесте.

Сильные решения для проекта

- Отчёт по моделям: RMSE, MAE, R^2 test, не только train R^2 .
- Для классификации SI > 8: balanced accuracy, MCC, не только accuracy.

4. Разработка структуры решения

Основные подходы из релевантных работ перенесены в EDA и FE в ноутбуке. Для упрощения процесса подбора параметров и определения лучшей модели сформирован единый для каждой цели порядок блоков:

1. Настройка

Определение глобальных переменных, путей к файлам

2. Загрузка данных

Функции для загрузки данных, работы со столбцами, формирования готовой структуры Dataset

3. Обучение

- создание единой спецификации моделей
- обучение всех моделей и формирование метрик

4. Сравнение результатов на графиках

5. Определение лучшей модели

6. Сравнение feature importance

Структура кода позволяет легко изменять набор обучаемых моделей, а также сетку поиска параметров.

5. Результаты

Для моделирования используется `output/indata_processed.csv` (998 соединений, 51 признак после исключения целевых столбцов).

Общие настройки:

- train/test 80/20,
- `random_state=42`
- подбор гиперпараметров - GridSearchCV, 5-fold
- в классификации - StratifiedKFold.

В фармакологии IC50 и CC50 измеряются в концентрациях, которые на практике варьируют на несколько порядков (в представленном датасете max/min для IC50 $\approx 10^6$, для SI - ещё сильнее). Это типичная ситуация для HTS и QSAR, и она напрямую влияет на выбор шкалы для ML.

Стандарт в QSAR и веб-сервисах - отрицательный десятичный логарифм молярной концентрации (чем выше pIC50, тем сильнее соединение). В проекте делаю также:

$$pIC50 = -\log_{10}\left(\frac{[IC50 (mM)]}{1000}\right), \quad pCC50 = -\log_{10}\left(\frac{[CC50 (mM)]}{1000}\right)$$

Источник (разд. 3)	Что рекомендуют	Как это подтверждается в проекте
Lagunin et al., 2025 (п. 3.3.2)	Регрессия IC50/GI50 в log-шкале, RMSE и R^2 на log-концентрации, на 20 линиях клеток $R^2 \approx 0.69$, RMSE ≈ 0.58	Без log таргетов линейные модели дают $R^2 \approx 0.32$ (pIC50), после pIC50 - до 0.55 (Extra Trees)
Frontiers in Pharmacology, 2018 (п. 3.3.3)	Для широкого диапазона IC50 регрессия в log-шкале стабильнее, чем на сырых mM или жёсткая бинаризация	Распределения IC50/CC50 в EDA сильно скошены, log сжимает хвосты
REDIAL-2020 (п. 3.3.1)	Параллельное моделирование potency и cytotox, фильтры по logP/logS в пространстве дескрипторов	pIC50 и pCC50 - отдельные регрессии, SI проверяется как CC50/IC50
Tropsha et al., 2010 (п. 3.6.1)	Курация данных, outliers, не смешивать шкалы при валидации	Метрики регрессии считаются в единицах pIC50/pCC50 на test и CV
"Beware of R ² " (п. 3.6.3)	Оценивать RMSE/MAE на test/CV, не train R^2 на сырых mM	RMSE pIC50 ≈ 0.68 интерпретируется как $\sim 5\times$ ошибка по концентрации

При интерпретации pIC50/pCC50 переводят мультипликативную ошибку ("в 10 раз промахнулся") в аддитивную на log-шкале - это соответствует гипотезе QSAR о линейной связи "структура $\rightarrow$ log-активность" (линейные модели Ridge/Linear становятся осмысленным baseline).

Решения для SI:

Источник	Рекомендация	Обоснование в данных
Frontiers, 2018 и REDIAL-2020	SI как производная potency и toxicity, поэтому надёжнее двухконтурная схема, чем одна "pSI"	SI согласован с CC50/IC50 ($\varepsilon_{rel} < 10^{-15}$), но имеет экстремальные выбросы ($\max \approx 1.6 \times 10^4$)
Comm. Chemistry, 2025 (п. 3.4.3)	Отбор по активности + non-cytotoxic, SI как фильтр	log1p сглаживает хвост без потери малых SI
Практика skewed targets (Tropsha,	Для сильно скошенных положительных величин - $\ln(1 + y)$	На сыром SI $R^2 \approx 0$, на log1p_SI - $R^2 \approx 0.37$, Spearman ≈ 0.44

Источник	Рекомендация	Обоснование в данных
обзор QSAR 2024, п. 3.1.3)		

$$\log_{10} p_{-SI} = \ln(1 + SI)$$

Обратное преобразование для интерпретации ранжирования: $SI = e^{\log_{10} p_{-SI}} - 1$.

Переход к log-шкале - следствие обзора литературы (разд. 3) и диагностики EDA: pIC_{50}/pCC_{50} для концентраций, $\log_{10} p_{-SI}$ для селективности. Все регрессии и сравнение моделей в п. 5.3–5.5 выполнены в этих шкалах, бинарные задачи (п. 5.6–5.9) используют исходные mM/SI, что согласуется с отдельной постановкой классификации (п. 3.3.3).

5.1 EDA

Исходно 1001 строка, 214 столбцов. После очистки остаётся 998 соединений:

- удалены 3 строки с пропусками в BCUT/PartialCharge
- 18 константных
- 16 почти константных признаков отброшены на этапе FE

Целевые переменные:

- IC50 - mM
- CC50 - mM
- SI - безразмерный

Показатель	Медиана	Среднее	Разброс (max/min)	Комментарий
IC50	46.0	222.8	$\approx 10^6$	Сильная правосторонняя асимметрия, поэтому нужна log-шкала
CC50	408.8	589.1	$\approx 6.5 \times 10^3$	То же, при этом выше IC50 по медиане
SI	3.86	72.5	$\approx 1.4 \times 10^6$	Экстремальные выбросы (max $\approx 1.6 \times 10^4$)

Проверка $SI = CC_{50} / IC_{50}$ на всём датасете: максимальная относительная ошибка $\approx 8.5 \times 10^{-16}$ - целевые величины согласованы.

Трансформации таргетов - см. обоснование в начале разд. 5. В файле `indata_processed.csv` сохранены столбцы `pIC50`, `pCC50`, `log10_p_SI` только как целевые, не как признаки X.

Связь структуры и активности (качественно).

- Распределения IC50/CC50/SI и scatter-графики показывают, что "хорошие" по SI соединения не образуют отдельного кластера в сырых mM - без преобразования таргетов линейные модели неприменимы.
- Radar-профили Lipinski для верхних/нижних 10% по SI: различия в TPSA, LogP, числе доноров Н-связи - молекулы с высокой селективностью чаще ближе к "drug-like" зоне, но перекрытие с низким SI велико.
- PCA по дескрипторам с цветом по SI: частичное разделение в 2D, но сильного линейного разрыва нет - ожидаемо умеренное качество ML-моделей.
- Тепловая карта корреляций: блоки VSA, Chi, BCUT сильно коррелируют между собой - заставляет провести жёсткий отбор признаков.

Вывод по EDA: датасет пригоден для QSAR при log-трансформации таргетов и отборе признаков. SI в исходной шкале - тяжёлый таргет из-за выбросов и связи с двумя шумными регрессиями.

5.2 FE

Идеи FE согласованы с разд. 3.

- TeachOpenCADD T002 (п. 3.2.1) - Lipinski/Veber, а также Wu et al., 2020 (п. 3.1.1) - не использовать сотни коррелированных VSA "как есть", а агрегировать
- RFS Li et al., 2021 (п. 3.5.1) - снижение избыточности
- Sun et al., 2020 (п. 3.4.1) - группировка токсичных `fr_*`
- ADMET benchmark 2025 (п. 3.2.2) - блоки дескрипторов и отбор
- DBPP-Predictor (п. 3.2.3) - профиль свойств вместо одного `qed`.

Этапы пайплайна

1. Очистка - удаление 18 константных и 16 низкодисперсных признаков и 3 строки с NaN в BCUT/PartialCharge.
2. Инженерия - ≈ 90 новых столбцов (ниже).
3. Отбор - пары с $|r| > 0.9$ (87 удалено, п. 3.5.1), затем Random Forest по важности отдельно для IC50, CC50, SI (REDIAL-2020, п. 3.3.1). В `indata_processed.csv` - 51 признак для X.

Созданные признаки (формула и источник идеи)

Плотность, размер, гибкость

Признак	Формула / смысл	Откуда идея
PackingDensity	HeavyAtomCount / LabuteASA	Топологическая «компактность» молекулы, Wu 2020 — конституционные и топологические

Признак	Формула / смысл	Откуда идея
		дескрипторы, связь размера и поверхности (RDKit LabuteASA)
MassDensity	MolWt / LabuteASA	Масса на единицу поверхности, аналог плотности для QSAR по физхим. свойствам (обзор QSAR 2024, п. 3.1.3)
FlexibilityPerMass	NumRotatableBonds / MolWt	Гибкость, нормированная на размер, Veber (2004) — rotatable bonds в критериях пероральной биодоступности (п. 3.2.1, T002)
FlexibilityPerRing	NumRotatableBonds / (RingCount + 1)	Гибкость относительно жёсткости каркаса, TeachOpenCADD T002 — баланс гибкости и колец

Гибридизация и ароматичность

Признак	Формула / смысл	Откуда идея
Sp2Fraction	1 - FractionCSP3	Доля sp^2 -углерода, Bickerton et al. (RDKit qed) — насыщенность vs плоскость
Sp3toSp2Ratio	FractionCSP3 / Sp2Fraction	Соотношение насыщенного/плоского каркаса, тренд к FractionCSP3 в drug discovery (Wu 2020)
AromaticToAliphaticRatio	(NumAromaticRings + 1) / (NumAliphaticRings + 1)	Преобладание ароматики, Sun 2020 — ароматические кольца и цитотоксичность (п. 3.4.1)
AromaticFraction	NumAromaticRings / (RingCount + 1)	Доля ароматических колец среди всех колец, Lagunin 2025 — aromatic rings в QSAR IC50

Drug-likeness и ADME-профиль

Признак	Формула / смысл	Откуда идея
DrugScore	$qed \times (1 - \frac{abs(MolLogP - 2.5)}{10})$	Комбинация QED (RDKit, Bickerton) и штрафа за LogP вне «лекарственного» окна, DBPP-

Признак	Формула / смысл	Откуда идея
		Predictor (п. 3.2.3) — профиль свойств, не один скаляр
LipinskiViolations	Число нарушений: MW>500, LogP>5, HBD>5, HBA>10	Правило Липинского, TeachOpenCADD T002 (п. 3.2.1)
LipinskiScore	Произведение «мягких» штрафов по каждому критерию (clip 0–1)	T002 — количественный drug- likeness вместо бинарного pass/fail
VeberPass	1, если NumRotatableBonds ≤ 10 и TPSA ≤ 140 Å ²	Veber et al. (2002) и T002 (п. 3.2.1) — пероральная биодоступность
TPSAperMass	TPSA / MolWt	Полярность на единицу массы, Lagunin 2025 и ADMET benchmark (п. 3.2.2) — TPSA в QSAR
TPSAperHeavyAtom	TPSA / HeavyAtomCount	Полярность на тяжёлый атом, то же
HBDplusHBA	NumHDonors + NumHAcceptors	Суммарная H-bond активность, Lipinski
HBDtoHBARatio	NumHDonors / (NumHAcceptors + ε)	Баланс доноров/акцепторов, T002

VSA: агрегаты по бинам (вместо 47 отдельных столбцов)

Для каждого семейства PEOE_VSA*, SMR_VSA*, SlogP_VSA*, EState_VSA*,
VSA_EState* :

Признак	Формула / смысл	Откуда идея
{prefix}_Total	Сумма площадей по бинам	Wu 2020 (п. 3.1.1): агрегировать VSA (sum), не кормить ML всеми бинами
{prefix}_Max	Максимальный бин	Выделение доминирующего хим. окружения на поверхности
{prefix}_Min	Минимальный ненулевой вклад	Контраст полярных/неполярных зон
{prefix}_Entropy	Нормированная энтропия распределения по бинам	"Разнообразие" распределения свойства на поверхности, аналог information content (I _{pc} , AvgI _{pc})

Дополнительно по заряду PEOE (эвристика номеров бинов RDKit):

Признак	Формула / смысл	Откуда идея
PolarVSATotal	Сумма PEOE_VSA с номером бина ≥ 7	Полярные/заряженные области, PEOE — Partial Equalization of Orbital Electronegativities (RDKit docs)
NonpolarVSATotal	Сумма бинов ≤ 6	Гидрофобная поверхность
PolarityRatio	PolarVSATotal / NonpolarVSATotal	Баланс полярности, SlogP_VSA и TeachOpenCADD — lipophilicity vs polarity

BCUT2D: сводные по парам HI/LOW

Burden matrix eigenvalues (RDKit BCUT2D_*). Пары MW, Charge, LogP, MR (п. 2, разд. BCUT):

Признак	Формула / смысл	Откуда идея
BCUT_{X}_Range	HI - LOW	Размах свойства на молекуле, Wu 2020 — BCUT как компактное 2D-представление
BCUT_{X}_Mean	(HI + LOW) / 2	"Центр" распределения
BCUT_{X}_Ratio	HI / (LOW + ϵ)	Асимметрия верхнего/нижнего хвоста

Топологические индексы (Chi, Карра, Balaban)

Признак	Формула / смысл	Откуда идея
ChiSum, ChiMean, ChiRange	Сумма / среднее / размах по всем Chi*	Сжатие коррелированного блока Chi (RFS, п. 3.5.1), классические connectivity indices (Kier & Hall)
BalabanNormalized	BalabanJ / $\ln(\text{HeavyAtomCount} + 1)$	Нормировка индекса Балабана на размер, Tropsha 2010 — учёт размера молекулы при сравнении
KappaShape	Kappa1 / (Kappa2 + ϵ)	Индексы формы Kier, топологическая форма vs разветвление
KappaCyclicity	Kappa3 / (Kappa1 + ϵ)	Цикличность / удлинённость каркаса
HallKierPerHeavyAtom	HallKierAlpha / $(\text{HeavyAtomCount} + 1)$	Параметр α на атом, кольца и "плотность" графа

Фрагментные группы (fr_* → счётчики)

SMARTS-фрагменты RDKit. Вместо 50+ отдельных fr_* в модель часто попадают агрегаты:

Признак	Группа фрагментов	Откуда идея
FragmentCount_AcidicGroups	fr_C00 , fr_C002 , fr_phos_acid	Sun 2020 - карбоксильные/кислотные группы и токсичность
FragmentCount_BasicGroups	амины, пиперидин/пиперазин	Базовость и заряд - ADMET, cytotox
FragmentCount_HBDGroups	спирты, фенолы, амиды	Lipinski HBD
FragmentCount_HBAGroups	эфир, эстеры, кетоны	Lipinski HBA
FragmentCount_AromaticGroups	бензол, гетероциклы	Lagunin и Sun - ароматика
FragmentCount_HalogenGroups	галогениды	Метаболизм, липофильность
FragmentCount_NitrogenGroups	нитрил, нитро, амины	Sun - fr_nitro , токсичные субструктуры
FragmentCount_ReactiveGroups	альдегид, эпексид, азо	Реакционная способность / токсичность
HasAny_{группа}	0/1 — есть ли хотя бы один фрагмент группы	Бинарный «фармакофорный» сигнал, REDIAL — фармакофоры
TotalFragmentCount	Сумма всех fr_*	Общая "функциональная насыщенность"
FragmentDiversity	Число различных типов fr_* с count>0	Разнообразие функциональных групп, важен для SI (top RF)

Нелинейные и парные признаки

Признак	Формула / смысл	Откуда идея
MolWt_sq , MolLogP_sq , TPSA_sq , RingCount_sq	Квадрат скаляра	Учёт нелинейности (пороги Lipinski, U-образные эффекты LogP), см. "Beware of R²" - нелинейные модели оправданы
MolWt_sqrt , ...	$\sqrt{x}$ для тех же	Смягчение масштаба

Признак	Формула / смысл	Откуда идея
LabuteASA_log , BertzCT_log , Ipc_log	$\log_{1p}(x)$ для скошенных дескрипторов	Стандарт для правосторонних распределений (аналог $\log_{1p_SI}$ для таргета)
MWxRotBonds	$MolWt \times$ $NumRotatableBonds$	Взаимодействие размера и гибкости, Veber
LogPxTPSA	$MolLogP \times$ TPSA	Классическое lipophilicity–polarity пространство, Lagunin 2025, top RF для IC50

Отбор признаков после FE

Шаг	Метод	Ссылка на литературу
Корреляция	Удаление одного из пары при $\ r\ > 0.9$	RFS Li 2021 (п. 3.5.1): в статье порог $\ r\ > 0.8$, я использую более мягкий 0.9
RF importance	Топ-признаки по IC50 , CC50 , SI отдельно	REDIAL-2020 и ADMET benchmark 2025 (п. 3.2.2)
Итог	51 признак в X	Соотношение $n/p \approx 20$ - разумно по Tropsha (п. 3.6.1)

Примеры прошедших отбор (top RF): FlexibilityPerMass , PEOE_VSA_Entropy ,
LogPxTPSA , для CC50 - TPSAperMass , MolLogP_sq , EState_VSA8 , для SI -
FragmentDiversity , VSA_EState_Entropy , EState_VSA2 .

Вывод по FE: признаки явно привязаны к ADME/QSAR-литературе (разд. 3), агрегация
VSA и fr_* снижает избыточность, а производные таргеты в X не используются
(исключение столбцов $pIC50$, $pCC50$, $\log_{1p_SI}$ при обучении).

5.3 Целевые переменные

Для построения регрессии сравнивались 8 моделей:

- Linear
- Ridge
- Decision Tree
- Random Forest
- SVR
- KNeighbors
- Hist Gradient Boosting
- Extra Trees

Оценка качества по

- RMSE
- MAE
- R2

Для построение классификатора сравнивались 3 модели

- Linear
- Random Forest
- Hist Gradient Boosting


Оценка качества по

- F1
- Balanced accuracy
- Precision
- Recall
- ROC-AUC

Для каждой модели выполнен GridSearchCV по индивидуальной сетке параметров.

5.3.1 Регрессия для pIC50

Сравнение показателей различных моделей.



Модель	Test RMSE	Test MAE	Test R^2
Linear	0.837	0.656	0.319
Ridge	0.837	0.660	0.320
Decision Tree	0.855	0.673	0.290
Random Forest	0.694	0.549	0.531
SVR	0.718	0.550	0.499
KNeighbors	0.706	0.534	0.516

Модель	Test RMSE	Test MAE	Test R^2
Hist Gradient Boosting	0.727	0.564	0.486
Extra Trees	0.682	0.524	0.548


Лучшая модель - Extra Trees ($R^2 \approx 0.55$ на test): по дескрипторам объясняется около половины дисперсии log-активности. Для ориентира: в QSAR по IC50 на клеточных линиях (Lagunin et al., 2025) на больших выборках $R^2 \sim 0.69$. При $n \approx 1000$ и ~ 50 признаков результат умеренный, но реалистичный. Параметры модели:

- criterion: friedman_mse
- min_samples_leaf: 1
- min_samples_split: 10
- n_estimators: 250

Линейные модели ($R^2 \approx 0.32$) заметно слабее ансамблей так как связь между структурой и potency нелинейна (фрагменты, VSA-бины, BCUT)

RMSE ≈ 0.68 в единицах pIC50 соответствует типичной ошибке порядка ~ 0.7 порядка по концентрации ($10^{0.7} \approx 5$ раз по mM). Для скрининга "порядок величины" приемлем, но для точного ранжирования кандидатов весьма ограниченно.

Сравнение важности признаков в различных моделях.




Наиболее важные признаки, которые выделяет Extra Trees:

Название	Доля важности	Расшифровка	Класс
KappaCyclicality	~7%	Цикличность / удлиённость каркаса	Топологические индексы
NHONCount	~5.5%	Число атомов N и O в группах NH/OH (доноры H-связи)	Drug-likeness и ADME-профиль
BalabanJ	~3.8%	Топологический индекс Балабана J (разветвление и "длина" молекулы)	Топологические индексы
VSA_EState8	~3.8%	Сумма E-State × площадь поверхности по бину VSA (бин 8)	VSA: агрегаты по бинам
EState_VSA2	~3.5%	Сумма площадей атомов по бину индекса E-State (бин 2)	VSA: агрегаты по бинам

5.4 Регрессия для pCC50

Сравнение показателей различных моделей.




Модель	Test RMSE	Test MAE	Test R^2
Linear	0.600	0.475	0.271
Ridge	0.596	0.472	0.281
Decision Tree	0.631	0.451	0.196
Random Forest	0.560	0.393	0.367
SVR	0.529	0.377	0.433
KNeighbors	0.583	0.389	0.313
Hist Gradient Boosting	0.582	0.406	0.315
Extra Trees	0.554	0.381	0.379

Лучшая на test - SVR ($R^2 \approx 0.43$), немного хуже Extra Trees (0.38) и RF (0.37). Качество ниже, чем для pIC50 - согласуется с литературой: цитотоксичность (CC50) часто шумнее и слабее связана с 2D-дескрипторами, чем противовирусная активность. $R^2 \approx 0.43$ означает, что модель улавливает общие тренды (липофильность, полярность, размер), но не предсказывает CC50 надёжно для отбора "безопасных" соединений без эксперимента.

Линейный baseline ($R^2 \approx 0.28$) снова слаб - для CC50 важны нелинейные пороги по TPSA/кольцам/фрагментам (`fr_*`), что видно в top RF для CC50.

Сравнение важности признаков в различных моделях.




Наиболее важные признаки, которые выделяет SVR:

Название	Доля важности	Расшифровка	Класс
KappaCyclicty	~9%	Цикличность / удлинённость каркаса ($Kappa3 / (Kappa1 + \epsilon)$)	Топологические индексы
VSA_EState5	~7%	Сумма E-State $\times$ площадь поверхности по бину VSA (бин 5)	VSA: агрегаты по бинам
VSA_EState4	~6.5%	Сумма E-State $\times$ площадь поверхности по бину VSA (бин 4)	VSA: агрегаты по бинам
MolLogP	~5.5%	Коэффициент распределения октанол/ вода (log P), липофильность	Drug-likeness и ADME-профиль
BCUT2D_LOGPHI	~4%	BCUT2D - Crippen LogP, high (верхняя граница по липофильности)	BCUT2D: сводные по парам HI/LOW

5.5 Регрессия для $\log_{10}p(SI)$

Сравнение показателей различных моделей.



Модель	Test RMSE	Test MAE	Test R^2
Linear	1.498	1.115	0.152
Ridge	1.500	1.119	0.150
Decision Tree	1.526	1.014	0.121
Random Forest	1.308	0.964	0.353
SVR	1.417	0.997	0.241
KNeighbors	1.410	1.041	0.250
Hist Gradient Boosting	1.320	0.963	0.342
Extra Trees	1.289	0.940	0.373

Для лучшей модели (Extra Trees) - оценка на исходной шкале SI (обратное преобразование $SI = e^y - 1$):

- корреляция Спирмена между истинным и предсказанным SI на test: $\rho \approx 0.46$, $p < 0.001$ - есть умеренная корреляция, но не точная численная оценка.
- Среднее $|SI_{pred} - SI_{true}|/SI_{true} \approx 0.83$ - на сырой шкале относительные ошибки огромны из-за выбросов SI.

$R^2 \approx 0.37$ на $\log_{10}p_SI$ - лучше, чем на сыром SI ($R^2 \rightarrow 0$), но слабее pIC50 и pCC50: SI - производная двух величин и даже хорошие модели IC50 и CC50 не гарантируют точный SI. Практический вывод: для отбора кандидатов надёжнее двухконтурная схема (отдельно низкий IC50 и высокий CC50 / фильтр SI > 8), чем одна регрессия на SI. Spearman ≈ 0.46 поддерживает использование модели для грубого ранжирования библиотеки, но не для количественного прогноза SI.

Делать обзор важности признаков у разных моделей нет смысла, так как все они слишком сильно ошибаются.


5.6 Бинарный классификатор на целевой признак IC50 > median(IC50)

Класс 1 - IC50 выше медианы (≈ 46 мМ), т.е. более слабая противовирусная активность

Класс 0 - более активные соединения

Баланс классов $\sim 50/50$

Сравнение показателей различных моделей.




Модель	F1	Balanced Acc	Precision	Recall	ROC-AUC
Logistic Regression	0.667	0.658	0.616	0.726	0.735
Random Forest	0.711	0.720	0.697	0.726	0.789
Hist Gradient Boosting	0.698	0.714	0.702	0.695	0.775

По сумме метрик на графиках сравнения лидирует Random Forest (3 из 5).

ROC-AUC ≈ 0.79 - модель разделяет "слабые" и "сильные" по IC50 лучше случайного, на уровне "приемлемо" для HTS-скрининга. Recall класса 1 ≈ 0.73 : чаще помечает слабоактивные - умеренный риск пропустить слабый препарат (FN), если цель - отсеять неактивные. Дескрипторы несут сигнал о potency, задача проще, чем классификация SI (см. 5.8–5.9).

Сравнение важности признаков в различных моделях.



Наиболее важные признаки, которые выделяет Random Forest

Название	Доля важности	Расшифровка	Класс
VSA_EState8	~4%	Сумма E-State × площадь поверхности по бину VSA (бин 8)	VSA: агрегаты по бинам
BCUT2D_MRLow	~3.5%	BCUT2D - molar refractivity, low (нижняя граница по молярной рефракции)	BCUT2D: сводные по парам HI/LOW
FlexibilityPerMass	~3%	Гибкость, нормированная на размер (NumRotatableBonds / MolWt)	Плотность, размер, гибкость

Параметры лучшей модели Random Forest

- criterion: entropy
- min_samples_leaf: 1
- min_samples_split: 5
- n_estimators: 100


5.7 Бинарный классификатор на целевой признак CC50 > median(CC50)

Класс 1 - CC50 выше медианы (≈ 409 мМ), т.е. ниже цитотоксичность (нужна большая концентрация для 50% гибели клеток)

Класс 0 - более токсичные

Баланс $\sim 50/50$

Сравнение показателей различных моделей.




Модель	F1	Balanced Acc	Precision	Recall	ROC-AUC
Logistic Regression	0.780	0.751	0.750	0.813	0.814
Random Forest	0.778	0.778	0.823	0.738	0.864
Hist Gradient Boosting	0.786	0.789	0.840	0.738	0.875

Лучшая по совокупности метрик - Hist Gradient Boosting (4 из 5).

ROC-AUC ≈ 0.88 - лучший результат среди всех классификаций: по RDKit-дескрипторам цитотоксичность (в терминах "выше/ниже медианы CC50") предсказывается заметно лучше, чем селективность. Высокая precision (≈ 0.84) у GBC: если модель говорит "низкая токсичность" (класс 1), это относительно надёжно, полезно для фильтрации "безопасных" кандидатов в EDA-конуре. Складывается с EDA: CC50 и Lipinski/полярность связаны сильнее, чем SI с одними только 2D-признаками.

Сравнение важности признаков в различных моделях.



Наиболее важные признаки, которые выделяет Hist Gradient Boosting

Название	Доля важности	Расшифровка	Класс
NHOHCount	~23%	Число атомов N и O в группах NH/OH (доноры H-связи)	Drug-likeness и ADME-профиль
BCUT2D_MRLow	~14%	BCUT2D - molar refractivity, low (нижняя граница по молярной рефракции)	BCUT2D: сводные по парам HI/LOW
EState_VSA3	~3.5%	Сумма площадей атомов по бину индекса E-State (бин 3)	VSA: агрегаты по бинам
BCUT2D_MWLOW	~3%	BCUT2D - molecular weight, low (нижняя граница по молекулярной массе)	BCUT2D: сводные по парам HI/LOW

Параметры лучшей модели Hist Gradient Boosting

- learning_rate: 0.1
- max_depth: 5


- max_iter: 200
- max_leaf_nodes: 31
- min_samples_leaf: 10

5.8 Бинарный классификатор на целевой признак SI > median(SI)

Класс 1 - SI выше медианы (≈ 3.86), более селективные соединения

Баланс $\sim 50/50$

Сравнение показателей различных моделей.




Модель	F1	Balanced Acc	Precision	Recall	ROC-AUC
Logistic Regression	0.670	0.680	0.691	0.650	0.650
Random Forest	0.667	0.665	0.663	0.670	0.698
Hist Gradient Boosting	0.680	0.680	0.680	0.680	0.710

Лучшая - Hist Gradient Boosting (4 из 5), но разрыв между моделями мал.

ROC-AUC ≈ 0.71 - слабее IC50 и CC50: разделить "селективнее медианы" можно лишь чуть лучше случайного. Balanced ассурасу ≈ 0.68 - на практике $\sim 2/3$ верных при равных классах, для ранжирования библиотеки недостаточно без экспериментальной проверки. Причина: SI - отношение двух шумных величин, порог по медиане не совпадает с биологическим порогом "хорошего" препарата (см. 5.9).

Сравнение важности признаков в различных моделях.



Наиболее важные признаки, которые выделяет Hist Gradient Boosting

Название	Доля важности	Расшифровка	Класс
BCUT2D_MRLOW	~24%	BCUT2D - molar refractivity, low (нижняя граница по молярной рефракции)	BCUT2D: сводные по парам HI/LOW
MolWt	~13.5%	Молекулярная масса (г/моль)	Плотность, размер, гибкость
BCUT_LogP_Mean	~10%	Среднее BCUT2D по липофильности: (BCUT2D_LOGPHI + BCUT2D_LOGPLOW) / 2	BCUT2D: сводные по парам HI/LOW
NHOHCount	~6.5%	Число атомов N и O в группах NH/OH (доноры H-связи)	Drug-likeness и ADME-профиль
BCUT2D_MWLOW	~6%	BCUT2D - molecular weight, low (нижняя граница по молекулярной массе)	BCUT2D: сводные по парам HI/LOW

Название	Доля важности	Расшифровка	Класс
qed	~5%	Количественная оценка лекарственности (0–1, drug-likeness)	Drug-likeness и ADME-профиль

Параметры лучшей модели Hist Gradient Boosting


- learning_rate: 0.05
- max_depth: 8
- max_iter: 100
- max_leaf_nodes: 41
- min_samples_leaf: 10

5.9 Бинарный классификатор на целевой признак SI > 8

Класс 1 - SI > 8 ("достаточная селективность")

Доля класса 1 в данных ≈ 36% - дисбаланс

Сравнение показателей различных моделей




Модель	F1	Balanced Acc	Precision	Recall	ROC-AUC
Logistic Regression	0.519	0.639	0.618	0.447	0.657
Random Forest	0.543	0.658	0.660	0.461	0.739

Модель	F1	Balanced Acc	Precision	Recall	ROC-AUC
Hist Gradient Boosting	0.556	0.663	0.649	0.487	0.749

Лучшая - Hist Gradient Boosting (4 из 5).

ROC-AUC ≈ 0.75 при дисбалансе - модель улавливает сигнал, но F1 ≈ 0.56 невысок: много ошибок по миноритарному классу "хорошая селективность". Recall ≈ 0.49 для класса SI > 8: модель пропускает около половины действительно селективных соединений - для скрининга "лучших" кандидатов недостаточно. Precision ≈ 0.65 : среди предсказанных (SI > 8) ложных положительных $\approx 35\%$. Вывод: порог 8 - жёсткий биологический критерий, без балансировки (class_weight, SMOTE) или метрик вроде PR-AUC / MCC качество ограничено. Можно пробовать комбинировать с регрессией pIC50/pCC50 и правилом "низкий IC50 + высокий CC50".

Сравнение важности признаков в различных моделях.



Наиболее важные признаки, которые выделяет Hist Gradient Boosting

Название	Доля важности	Расшифровка	Класс
KappaCyclicity	~17%	Цикличность / удлинённость каркаса ($Kappa3 / (Kappa1 + \epsilon)$)	Топологические индексы
FlexibilityPerMass	~13.5%	Гибкость, нормированная на размер ($NumRotatableBonds / MolWt$)	Плотность, размер, гибкость
BCUT2D_MRLow	~11%	BCUT2D - molar refractivity, low (нижняя граница по молярной рефракции)	BCUT2D: сводные по парам HI/LOW
ESate_VSA3	~6%	Сумма площадей атомов по бину индекса E-State (бин 3)	VSA: агрегаты по бинам
VSA_ESate_Entropy	~4%	Нормированная энтропия распределения VSA_ESate по бинам	VSA: агрегаты по бинам
FpDensityMorgan1	~3.5%	Доля установленных битов в отпечатке Morgan (радиус 1)	Отпечатки Morgan

Параметры лучшей модели Hist Gradient Boosting

- learning_rate: 0.05
- max_depth: 5
- max_iter: 100
- max_leaf_nodes: 21
- min_samples_leaf: 30

6. Выводы

В работе на выборке 998 соединений и 51 молекулярном признаке (после FE и отбора) решены семь связанных задач QSAR: три регрессии на преобразованных таргетах (pIC50, pCC50, log1p_SI) и четыре бинарные классификации на исходных шкалах IC50, CC50 и SI. Единый пайплайн (GridSearchCV, 5-fold, hold-out 20%) и сопоставимые метрики позволяют сравнить задачи между собой.

Данные и признаки

EDA подтвердил пригодность датасета для классического QSAR при log-трансформации концентраций и агрессивном снижении избыточности дескрипторов. Сильная асимметрия IC50/CC50/SI и согласованность SI = CC50/IC50 обосновали отказ от моделирования сырых mM в регрессии. Feature engineering (~90 новых

признаков, отбор по $|r| > 0.9$ и RF importance) дал компактный набор, в котором доминируют не отдельные fr_* , а сводные характеристики: VSA/E-State, BCUT2D, топология (Kappa, Balaban), ADME-скаляры и парные комбинации (LogPxTPSA, FlexibilityPerMass).

Модели и метрики

Регрессия.

Линейные модели (Linear, Ridge) стабильно слабее ансамблей и SVR: для pIC50 $R^2_{\text{test}} \approx 0.32$, для pCC50 ≈ 0.28 , что указывает на нелинейную связь "2D-структура $\rightarrow$ активность". Лучшие результаты на test:

Задача	Модель	Ключевая метрика (test)	Интерпретация
pIC50	Extra Trees	$R^2 \approx 0.55$, RMSE ≈ 0.68	Объясняется ~половина дисперсии log-активности, ошибка ~5x по концентрации
pCC50	SVR	$R^2 \approx 0.43$, RMSE ≈ 0.53	Умеренный прогноз цитотоксичности, слабее potency
log1p_SI	Extra Trees	$R^2 \approx 0.37$, Spearman ≈ 0.46	Пригодно для грубого ранжирования, не для точного SI

Классификация.

Бинарные пороги по медиане IC50/CC50 дают ROC-AUC 0.79 и 0.88 соответственно, и задача CC50 > median - наиболее успешная в проекте (высокая precision у Hist Gradient Boosting). Селективность предсказывается хуже: SI > median (ROC-AUC ≈ 0.71), SI > 8 при дисбалансе 36% (ROC-AUC ≈ 0.75 , F1 ≈ 0.56 , recall миноритарного класса ~ 0.49). Это согласуется с тем, что SI - отношение двух шумных измерений, а порог 8 - жёсткий биологический критерий, не совпадающий с медианой выборки.

Среди алгоритмов нет одного универсального лидера: Extra Trees силён в регрессии potency/SI, SVR - в pCC50, Random Forest - в IC50 > median, Hist Gradient Boosting - в задачах CC50 и SI. Для production-скрининга разумна двухконтурная схема: отдельно модель активности (IC50 / pIC50) и модель токсичности (CC50 / pCC50), с правилом или вторым классификатором по SI > 8, а не единая регрессия на SI.

Типичные дескрипторы в лучших моделях

По важности признаков (топ-3–5 у лучших моделей по задаче) повторяются следующие группы:

- Топологические индексы (FE, блок F): KappaCyclicity - лидер в pIC50, pCC50 и SI > 8, отражает форму и цикличность каркаса.
- VSA / E-State: VSA_EState*, EState_VSA*, VSA_EState_Entropy - распределение электротопологического состояния на поверхности, важны для IC50 и CC50.

- BCUT2D: BCUT2D_MRLow , BCUT2D_MWLow , BCUT2D_LogP_{HI} , BCUT_LogP_Mean - компактное 2D-представление массы, рефракции и липофильности, доминируют в задачах по SI.
- ADME / drug-likeness: NH_{OH}Count , MolLogP , qed - доноры H-связи, липофильность, общая "лекарственность", особенно заметны в CC50 > median.
- Плотность и гибкость: FlexibilityPerMass , MolWt - нормированная гибкость и размер, встречаются в IC50 и SI > 8.
- Отпечатки Morgan: FpDensityMorgan1 - локальная структурная "плотность" в задаче SI > 8.

Итог: модели опираются не на один скаляр Lipinski, а на комбинацию топологии, поверхностных бинов и BCUT - в духе рекомендаций литературы (Wu 2020, ADMET benchmark, REDIAL).

Потенциал для улучшения

1. Валидация: nested CV / внешний тестовый набор, Y-scrambling, оценка applicability domain (разд. 3.6) - снизить риск оптимистичной оценки после FE и GridSearch на тех же данных.
2. SI и дисбаланс: class_weight , SMOTE, PR-AUC/MCC для SI > 8, двухэтапный отбор "низкий IC50 + высокий CC50" вместо одной регрессии log1p_SI.
3. Признаки: 3D-дескрипторы, фингерпринты (ECFP) целиком, механизм-специфичные фрагменты, отдельный отбор признаков внутри CV, чтобы не было утечки из test.
4. Модели: стекинг pIC50 + pCC50, калибровка вероятностей для классификаторов, сравнение с простым baseline "предсказать медиану".
5. Данные: курация выбросов по остаткам модели, расширение выборки, а при возможности - разбиение по химотипам/сериям соединений, чтобы test не содержал близкие аналоги train (scaffold split).

Поставленные задачи выполнены: для каждого таргета подобраны модели, метрики на test и интерпретация важности признаков. Практическая ценность наиболее высока для скрининга по IC50 и CC50 (регрессия в log-шкале и бинарные пороги), а прогноз SI целесообразно использовать только как вспомогательное ранжирование или фильтр в связке с двумя основными контурами. Полученные R^2 и ROC-AUC умеренны относительно крупных промышленных QSAR, но реалистичны для $n \approx 10^3$, ~50 признаков и только 2D-RDKit без структурной химии мишени - что само по себе является содержательным результатом исследования.